

VLessHallu

2026 年 8 月 10 日

摘要

进行了 60 次方法抽卡，并对 novelty 分数较好的进行了人工查看。结果较差。
又尝试撮合提供的 4 个文献方法到一起，结果散是满天星，聚是一坨 \$hit。

目录

1 研究问题	3
1.1 目标问题	3
1.2 方法要求	3
1.3 RoPE 与历史 KV	4
2 抽卡自动 review 标准	4
3 当前 VLessHallu 工程	4
第一部分 手动审查后失败的典型 idea	5
4 Prospective Evidence Coalition KV Control	5
4.1 原始方案	5
4.2 用户质疑一：所谓未来预测只是多步贪心	6
4.3 用户质疑二：计算量不可接受	6
4.4 最终判断	6
5 Hall-Certified Prospective Matching Cache	7
5.1 原始动机：逐项可信不等于联合可满足	7

5.2	原始算法设计	7
5.2.1	未来实体与视觉实例	7
5.2.2	Claim-region 边权	8
5.2.3	Hall 证书与最小恢复	8
5.3	用户质疑一：六根手指数成五根并非 Hall deficiency	9
5.4	用户质疑二：边权是否真的优于 attention	10
5.5	与最相近 counting 工作的比较	10
5.6	更广 related work 边界	11
5.7	最终判断：算法切口独特，但作为方法是下位替代	11
6	Future Margin Basis Cache	12
6.1	原始动机与算法	12
6.2	第一层问题：线性张成不等于保留实际 margin	12
6.3	用户的关键反驳：错误地静态化自回归查询	13
6.4	第二层问题：signed veto 与 RRQR 不匹配	14
6.5	机制级 related-work 查杀	14
6.6	最终判断	15
第二部分	总结	16
7	反复出现的错误	16
7.1	成熟算法超级大聚合	16
7.2	切入似乎很对，实际非常狭隘	16
7.3	多步预测在自回归生成模式下的严谨性问题	16
8	采用自动科研提示词，追加十轮	16
第三部分	完整 Idea 1–60 摘要	19

1 研究问题

1.1 目标问题

面向多模态大模型的看图幻觉，在无需额外训练的条件下，利用未来解码轨迹预测视觉幻觉风险，并据此动态管理历史视觉 KV cache。

总之目标减少幻觉。约束一不改主模型，约束二利用投机解码类似的方法预测或使用未来 $1 \sim k$ 个 token 的轨迹预测幻觉，约束三必须通过 kv cache 管理实现，无论是暂时禁用部分历史还是对即将生成的 1 个 token 对 kv 进行操作。

任务面向参考文献中 Chair 等 benchmark。目标模型建议三个 7B–8B MLLM，例如 LLaVA、Qwen-VL 与 InternVL；核心数据集为 AMBER、CHAIR 与 MMHal-Bench。期望提升不能只是微弱正数，而应在可复现条件下具有统计意义，理想幅度为 5%–10% 或以上。

任务和 4 个参考文献关联性很强，一定要看

1. https://openaccess.thecvf.com/content/CVPR2026/html/Jiang_KVSmooth_Mitigating_Hallucination_in_Multi-modal_Large_Language_Models_through_Key-Value_CVPR_2026_paper.html 2. <https://aclanthology.org/2026.findings-acl.1447/> 3. <https://arxiv.org/abs/2510.19183> 4. https://openaccess.thecvf.com/content/CVPR2026F/html/Zhuang_Myopia_Rectification_KV_Cache_Pruning_for_MLLMs_Via_Dynamic_Attention_CVPRF_2026_paper.html

否则不考虑其他直接 autoresearch 大概率会重叠并收获 reject 三连：

Weaknesses

- Questionable motivation.
- Incremental contribution.
- Low-quality artifact.

1.2 方法要求

- 不增加主模型训练，不依赖新标注或额外幻觉判别模型；最好是一键外接那种。
- 只围绕该差异设计一个不可被现有 attention/value/lookahead/verification 直接替代

的最小干预；

- 在写出 forward-equivalent 成本与最强 related-work kill test 后，才进入最小 pilot。

在完成这一步之前，继续生成第 61 个“数学对象加视觉 KV”候选的边际价值很低。按用户停止规则，本档案到 Idea 60 为止，不补做本地实验。

1.3 RoPE 与历史 KV

物理移除某些历史视觉 KV 并不必然要求重新计算所有后续 KV。若实现保留每个 cache entry 的原始位置并在 attention 中使用正确位置，剩余 K/V 可以继续使用；真正危险的是把压缩后的物理索引误当成新的序列位置，或改写已经正式生成的文本前缀。当前 VLessHallu 代码将原始位置单独跟踪，并只裁剪视觉 token，文本和已生成 token 不进入删除集合，因此该工程路径与“修改历史文本后整体重算”不同。

简单来说，在 causalLM 下，你可以禁用前面的 kv cache，但不要删除或插入，否则操作区域之后的所有 kv cache 必须重算。

2 抽卡自动 review 标准

- (1) 第一位 reviewer 为独立 xhigh 5.6 subagent，明确要求不查看记忆，并必须打开工具检索 related work；
- (2) 只有第一审严格大于 7，才调用 OpenRouter 的 Gemini 3.1 Pro 与 Grok 4.5，二者均开启 web search；不过我建议 gemini 换 claude，gemini 给的分虚高
- (3) 三位 reviewer 的分数必须全部严格大于 7，平均分和最高分均不能补偿最低分；
- (4) 某一候选失败后才生成下一候选；达到 50 个后停止，后经用户允许借鉴自动科研项目再追加最多 10 个；
- (5) 整个方向搜索阶段不运行本地模型实验。

3 当前 VLessHallu 工程

主要由 gpt 实现了四篇参考文献的复现 benchmark。包括 baseline、单独方法和聚合方法。结果是散着都很好，放一起分数一般。注意当前放一起是没有任何 novelty 的，属于 incremental contribution 的同时，也没有在所有方面有更优结果，特别是 CHAIRS-F1。

第一部分 手动审查后失败的典型 idea

本部分优先记录用户逐步追问、机制拆解和 related-work 查杀过的方向。

结论不只依据初始 novelty 分数，而是考察方法是否符合真实自回归过程、是否被更直接方法支配、是否有足够作用域，以及核心算法能否在不过度增加计算的条件下成立。

后面就是 AI 自己写的 idea 和总结了。

4 Prospective Evidence Coalition KV Control

4.1 原始方案

Idea 1 的暂定题目为 *Look Before You Ground: Prospective Evidence Coalitions for Training-Free Hallucination Control in MLLMs*。其核心不是预测一个抽象风险分数，而是提前暴露模型将要作出的语义承诺，再通过视觉失明与区域恢复实验寻找能改变该承诺的最小证据 coalition。

设当前正式 cache 为 C_t 。每隔 m 个真实 token，从 C_t 分叉生成长度为 h 的临时轨迹

$$\hat{y}_{t+i} = \arg \max_y p(y \mid C_t, \hat{y}_{t+1:t+i-1}).$$

草稿不会提交。固定草稿后，分别在完整视觉 KV 与视觉 null-KV 下 teacher-forced replay。若未来位置 j 的高置信承诺在拿走视觉信息后仍几乎不变，则定义其语言先验风险为

$$R_j = C_j \exp \left(-\frac{|M_j^{\text{full}} - M_j^{\text{null}}|}{\tau} \right).$$

从 null-KV 开始分组恢复视觉区域，并求

$$S^* = \arg \max_S \sum_j R_j D_{\text{JS}}(p_j^S, p_j^{\text{null}}) - \lambda |S| - \beta \sum_j (1 - R_j) D_{\text{KL}}(p_j^S, p_j^{\text{full}}).$$

最后丢弃整个预览分支，回到 C_t ，在正式解码时给 coalition 对应的原始视觉 KV 施加连续门控。因为正式前缀没有被改写，K/V 也不需要按新文本重算；这里的“回滚”只是丢弃临时分支。

直观例子是：模型当前写到“图片中，一名男子正在”，预览分支准备生成“骑着一匹棕色的马”。在 full 与 null replay 中，如果“马”在失明后仍很高，就表明它主要来自语言先验。逐区域恢复时，若人物下方区域使“马”下降而“自行车”上升，则回到正式分支后加强该区域，再让模型重新决定下一个 token。

4.2 用户质疑一：所谓未来预测只是多步贪心

用户首先指出，未来轨迹本质上是多步 greedy：同一个模型把将来的 token 提前跑了一遍，却不接受这些 token。这个判断是准确的。方案没有新预测器，future draft 只是一个不提交的 lookahead，类似 speculative decoding 的 draft 阶段，却没有 verifier acceptance 带来的计算复用。

这带来三项问题：

- 单条 greedy 轨迹有 tunnel vision，早期一步变化会使后续风险估计整体失效；
- full/null 分支并非同时描述真实未来，只是固定同一草稿后的局部对照；
- “某区域能改变马的概率”只证明因果影响，不保证它会把输出改成正确的自行车。

因此，正确的机制表述应是

未来预览 → 视觉失明测试 → 区域恢复定位 → 回到当前时刻重新生成，

而不是把 future trajectory 本身宣称为创新。

4.3 用户质疑二：计算量不可接受

设每 $m = 8$ 个正式 token 触发一次探测，lookahead 长度 $h = 8$ ，图像分成 $G = 16$ 个区域。一次探测包含：

- 未来预览：8 步；
- null-visual replay：8 步；
- 16 个区域恢复： $16 \times 8 = 128$ 步；
- 原本就要执行的正式生成：8 步。

总计约为 152 步，相对原本 8 步接近 $19\times$ 。把区域分支放进 batch 只能改善 wall-clock latency，不能降低总 FLOPs，且会增加显存。

三个表面修补都会让 novelty 消失：

- (1) 用一次反向传播同时估计所有区域影响，成本降到约 2-3 倍，但会接近 LIME 的 inference-time relevance/KV optimization；
- (2) 直接使用未来 query attention 排序，成本较低，却退化为 LAQ、MM-ShiftKV 或 PruneHal 一类 future-query/cache scoring；
- (3) 接受 preview token 以避免浪费，则变成 speculative decoding，而且危险 token 一旦被接受就来不及提前纠正。

4.4 最终判断

Idea 1 的 8/8.5/8 来自旧的无联网 reviewer 协议，只说明完整包装在表面上显得新颖，不能覆盖用户发现的工程否决。该方向最终为 **淘汰**：它以大量反事实分支换取定位

精度，不符合“不过度增加推理开销”的硬约束。后续方向不得再次把“多步预览、丢弃、分组遍历、正式重跑”包装成轻量 future-aware 方法。

5 Hall-Certified Prospective Matching Cache

5.1 原始动机：逐项可信不等于联合可满足

该方向试图解决一种逐 claim 分数无法表达的错误：多个未来实体声明分别具有较高视觉分数，但它们实际重复使用同一个视觉区域作为证据。设未来短语包含实体槽

$$C = \{c_1, \dots, c_m\},$$

视觉侧包含实例级候选区域

$$R = \{r_1, \dots, r_n\},$$

任意 grounding 前端给出支持矩阵

$$s_{jr} = \text{GroundScore}(c_j, r).$$

逐 claim 判断只考察

$$q_{\text{ind}} = \min_j \max_r s_{jr},$$

因此允许不同实体槽无限复用同一区域。Hall 版本要求不同实体具有不同视觉见证：

$$\gamma(C, R) = \max_{\pi \text{ injective}} \min_j s_{j, \pi(j)}.$$

恒有 $\gamma(C, R) \leq q_{\text{ind}}$ 。两者之差

$$\kappa = q_{\text{ind}} - \gamma$$

是 evidence collision gap，用于刻画“每个声明单独看似可信，但整组声明无法同时成立”。

例如，图中只有一只狗，模型准备生成“两只狗”，支持矩阵为

$$S = \begin{bmatrix} 0.93 & 0.08 \\ 0.91 & 0.07 \end{bmatrix}.$$

第一列是真狗区域，第二列是草地区域。逐项分数为 $q_{\text{ind}} = 0.91$ ，但单射匹配必须把一个实体分配给草地，因此 $\gamma = 0.08$ 。Hall 方法希望显式暴露这种视觉证据的重复记账。

5.2 原始算法设计

5.2.1 未来实体与视觉实例

每隔 L 个正式 token，运行长度为 h 的低频 shadow draft，不提交草稿内容，只提取即将出现的实体、数量、属性和关系。数词 k 被展开为 k 个可交换实体槽；属性附着

于实体，不额外占用独立区域。例如，“两只棕色狗”形成两个带棕色属性的狗实例，而不是把“棕色”当成第三个实体。

视觉侧不能直接把每个 patch 当作对象。原方案拟对相关视觉 token 的二维位置与响应做局部峰值检测和连通聚类，得到区域集合 R 。这是方法成立的关键前提：若视觉编码器已经把六根手指压成五个不可分离响应峰，后续匹配无法凭空恢复第六个实例。

5.2.2 Claim-region 边权

原始边权为

$$w_{jr} = \sum_{\ell, h} \sum_{i \in r} a_{ji}^{\ell h} \langle W_O^{\ell h} v_i, U(c_j) - U(\bar{c}_j) \rangle,$$

其中 $a_{ji}^{\ell h}$ 是 future claim 对视觉 token 的 attention, v_i 是 value, $U(c_j) - U(\bar{c}_j)$ 是 claim 相对竞争语义的输出方向。该定义要求区域既能被 future query 寻址，又确实向 residual stream 写入支持该 claim 的内容。

为了更直观，可拆成

$$A_{jr} = \sum_{i \in r} a_{ji}, \quad \bar{v}_{jr} = \frac{\sum_{i \in r} a_{ji} v_i}{A_{jr} + \epsilon},$$

$$S_{jr} = \langle U(c_j) - U(\bar{c}_j), W_O \bar{v}_{jr} \rangle, \quad w_{jr} = A_{jr} S_{jr}.$$

其含义是

读了多少 $\times$ 读到的内容在支持还是反对什么。

实际建图时，比直接按乘积排序更稳妥的形式是双条件：

$$(c_j, r) \in E \iff A_{jr} \geq \tau_A \quad \wedge \quad S_{jr} > \tau_S.$$

该定义形成逐区域贡献账本：

$$\sum_r w_{jr} = \left\langle U(c_j) - U(\bar{c}_j), W_O \sum_i a_{ji} v_i \right\rangle.$$

左侧是局部直接语义贡献，右侧是整个视觉 attention output 在目标方向上的写入。它不是完整 causal importance；删除区域后 softmax 会重新归一化，后续层也会改变。

5.2.3 Hall 证书与最小恢复

对阈值 τ 建立二部图

$$E_\tau = \{(c_j, r) : s_{jr} \geq \tau\}.$$

令 $\nu(G_\tau)$ 为最大匹配大小，则

$$\delta_\tau = m - \nu(G_\tau) = \max_{X \subseteq C} (|X| - |N_\tau(X)|).$$

当 $\delta_\tau > 0$ 时, 不存在让所有未来实体同时获得不同视觉见证的分配。最大化式中的 X 是可解释 Hall witness。实现中不必枚举所有子集: 先求最大匹配, 再从未匹配实体做一次 alternating-path 搜索即可取得 deficient set。

原方案还考虑逐渐降低 τ , 计算最大瓶颈匹配

$$\tau^* = \max_M \min_{(c,r) \in M} w_{cr},$$

以区分“完全不可匹配”与“只能依赖极弱边才能匹配”。

设 $A \subseteq R$ 为 active visual cache 的区域, R 为可恢复的完整视觉区域池。分别计算

$$\delta_{\text{active}} = m - \nu(G_\tau[C, A]), \quad \delta_{\text{full}} = m - \nu(G_\tau[C, R]).$$

由此区分:

- (1) $\delta_{\text{active}} = 0$: 当前 cache 足以支持未来实体;
- (2) $\delta_{\text{active}} > 0$ 且 $\delta_{\text{full}} = 0$: 风险由 KV pruning 引起, 完整 cache 仍有足够证据;
- (3) $\delta_{\text{full}} > 0$: 完整视觉表示也不能支持未来声明, 是内容级 overclaim。

对第二种情况, 原方案求

$$M^* = \arg \min_{M \text{ 为完整匹配}} \sum_{(c_j, r) \in M} \mathbf{1}[r \notin A],$$

即恢复使联合匹配重新可行所需的最少冷区域。例如红狗 claim 与普通狗 claim 都占用 active cache 的红狗区域, 而黑狗区域在冷端, 则沿

$$C_{\text{red}} \rightarrow r_{\text{red}} \rightarrow C_{\text{dog}} \rightarrow r_{\text{black}}$$

恢复黑狗区域并重新分配, 而不是为两个 claim 分别做 top- k 。

更复杂的版本还计划保留最大匹配、最小 Hall-deficit cut 与交替路径交换集中的 KV, 并用 transversal matroid 或 capacitated b -matching 表述“匹配基及其交换集保持未来可匹配性”。这些保证只对已经构造出的支持图成立, 不能反向证明该图忠实反映图像。

5.3 用户质疑一: 六根手指数成五根并非 Hall deficiency

gpt 指出“六根手指的图经常被模型认成五根”是现实对应。人工复核发现, 这个例子恰好揭示单向 Hall 的方向性缺陷。

若图中有六个可分视觉实例, 而模型只声明五个, 则

$$|C| = 5, \quad |R| = 6, \quad |M| = 5.$$

五个语言槽都能匹配到不同手指, Hall 条件完全满足; 未被语言提及的第六根手指不会产生 claim-side deficiency。单向 Hall 能检测的是相反情况: 图中只有五根, 模型却准备声明六根, 此时 $|C| = 6 > |R| = 5$, 至少一个语言槽没有独立视觉见证。

若要同时检测漏报，需要加入双向实例核算

$$d_{\text{over}} = |C| - |M|, \quad d_{\text{omit}} = |R^*| - |M|,$$

其中 R^* 必须是可靠目标实例集合，不能是所有视觉 patch。否则开放式 caption 中未被提及的背景对象会产生大量假阳性。一旦方法必须可靠构造 R^* 并检查视觉侧覆盖，它就开始直接估计实例总数，迅速退化为比现有 counting 系统更间接的计数方法。

5.4 用户质疑二：边权是否真的优于 attention

在没有实验或消融时，不能证明 w_{jr} 会在 benchmark 上优于 attention。能给出的只有信息不足反例：保持 Q 、 K 和 attention 完全不变，只改变某区域的 V ，区域对 claim 的支持语义已经改变，但任何 attention-only 规则输出不变。因此 attention 不能普遍识别“被读取的区域是在支持还是反对 claim”。

这只能证明 attention-only 不充分，并不证明 $A_{jr}S_{jr}$ 最优。它还受到删除后的 softmax 重归一化、后续 MLP/attention 传播、输出方向选择和竞争项 $\bar{c}_j$ 定义影响。因此 w_{jr} 最多应称为 *local direct semantic contribution*，只能作为可替换边构造器，不能作为核心创新。

只在一个近输出层计算时，额外算术量约为

$$O(hN_vd_h).$$

图匹配本身不重。真实开销风险来自 future draft，以及导出 attention 时可能退出 FlashAttention 快速路径。“图算法复杂度低”不等于整套方法低成本。

5.5 与最相近 counting 工作的比较

其他相关结果进一步压缩空间：[Quantity Matters](#) 已定义 number hallucination 并用一致性训练缓解；[Counting to Four Is Still a Chore for VLMs](#) 指出计数信息可能在视觉投影处较强，却在语言层衰减并受文本先验干扰；[Multi-Object Hallucination](#) 已验证多对象场景增加幻觉风险。

Hall 尚可守住的窄问题只有

$$q_{\text{ind}} \geq \tau \quad \text{但} \quad \gamma < \tau,$$

即每个 claim 独立看都有高分证据，但多个 claim 因复用同一实例而无法同时成立。若进一步满足

$$\gamma_{\text{full}} \geq \tau, \quad \gamma_{\text{active}} < \tau,$$

则错误可归因于视觉 KV pruning 破坏实例多样性。这是 counting 工作未直接覆盖、也最有辨识度的窄切口。

工作	核心做法	与 Hall 的重叠和差异	对 Hall 的威胁
CounterCount	构造违反常识数量的图像，如额外手指、耳朵或轮子；提供部件 mask/框，在推理时放大目标视觉 token 并压低背景 attention	现象与干预对象最接近。Hall 把数量展开为多个实例槽并要求不同 witness, 但 CounterCount 对目标现象更直接	很高。若 Hall 最终也是定位部件并增强区域，它只是复杂替代
LVLm-COUNT	使用 GroundingDINO、SAM 与分治图像分别计数，避免切分造成重复计数	二者都要求实例不可重复消费。Hall 可输出 deficient set 与 active/full cache 差异，但自身不提供可靠实例分割	很高。若使用相同检测前端，“一实例只能匹配一次”容易被视为图匹配重述
The Count Is There, but Mis-aligned	训练 count、output-count 与 error probes; 高风险时重新提示或 activation steering	都在内部提前检测数量错误。该工作给全局错误概率; Hall 可指出具体冲突和恢复区域	中高。若 Hall 只是 deficit 触发重生成，它像一个更脆弱的手工 detector

5.6 更广 related work 边界

Hall 的外围组件均位于拥挤赛道：

- LAQ 与 LookaheadKV 已利用 future query/lookahead 管理 KV；
- PruneHal 与 KVSmooth 已直接面向多模态幻觉干预视觉 KV；
- SADT 已指出高 attention 不代表 value 真正支持输出词；
- VLDet 等 grounding 工作已使用区域-语言二部匹配。

未找到完全等价的“future entity Hall deficit 加 active/full cache 增广恢复”，但 reviewer 很容易将整体概括为

future lookahead + region-word matching

+ Hall 后处理 + hallucination-aware KV restoration.

Hall 定理本身不能证明论文贡献独立于这些前端。

5.7 最终判断：算法切口独特，但作为方法是下位替代

正式 novelty 评分为 8.2/9/7，不满足三位 reviewer 均严格大于 7。用户的人工结论比 novelty 分数更直接：

Hall 是现有计数和局部视觉干预方法的下位替代：算法形式新，但在目标任务上不完整且未必有用。

淘汰理由为：

- (1) 单向 Hall 能检测 over-count，却不能检测用户给出的典型 under-count；
- (2) 加入双向覆盖后与 counting 高度重叠，并在开放 caption 中产生未提及对象假阳性；

- (3) 方法依赖视觉编码器先形成稳定实例区域，而这正是手指、相邻物体和细粒度部件中最不可靠的一环；
- (4) CounterCount、LVLM-COUNT 与内部 count probe 提供更直接的诊断或修正；
- (5) w_{jr} 只是局部语义分解，不能在无消融时证明优于 attention；

因此该方向不应作为主论文继续投入。可保留的仅是诊断思想：*individually plausible claims may compete for the same visual witness*。只有先证明 evidence collision 在 AMBER、CHAIR 或 MMHal-Bench 中高频出现，才值得重新考虑轻量诊断版本。

6 Future Margin Basis Cache

6.1 原始动机与算法

Future Margin Basis Cache (FMBC) 不再给每个视觉 token 一个标量重要度，而试图判断哪些视觉 token 对多个未来词表决策提供不可相互替代的证据方向。

对未来位置 t 的草拟 token y_t 与竞争 token a ，定义

$$m_{t,a} = z_t(y_t) - z_t(a).$$

对视觉 token i 构造贡献向量

$$c_i = [c_{i,1}, c_{i,2}, \dots, c_{i,M}]^\top,$$

其中 $c_{i,j}$ 是该 token 对第 j 个 future margin 的有符号局部贡献。将这些列组成

$$C = [c_1, c_2, \dots, c_{N_v}].$$

原始算法包含三步：

- (1) 用 rank-revealing QR 或 column subset selection (CSS) 选择少数线性独立证据列；
- (2) 强制保留无法由正向证据列重构的负向 veto 列；
- (3) 用精简 cache 重放 future block，若 margin 误差过大，则补回投影 residual 最大的视觉 token。

直观例子是：两个苹果区域对“苹果”和“红色”的 future margins 提供近似方向，一个低 attention 的空桌面区域独自否决“有杯子”。FMBC 希望保留一个苹果代表和空桌面 veto，而不是两个相似苹果区域。

人工复核前，该方向初审 novelty 为 7.5，Grok 搜索复审为 7，Gemini 没有返回有效 JSON，因此本来就未满足严格门槛。

6.2 第一层问题：线性张成不等于保留实际 margin

即使若干贡献列近似共线，也不能只留其中一列。若一百个弱证据沿同一方向累积，保留一个代表会保留 span，却丢失总 margin mass。删除 token 还会改变 softmax 归一

化，使完整 cache 上测得的 c_i 不再适用于精简 cache。

因此原方案至少还要同时约束：

- 贡献方向覆盖；
- signed margin mass 保真；
- reduced-cache replay 后的实际 margin 误差。

一旦正确性依赖 reduced-cache verification, RRQR 就不再提供核心保证，只是初始候选启发式。

6.3 用户的关键反驳：错误地静态化自回归查询

默认 Transformer attention 并不存在视觉 token top- k 。在未压缩的基线中，所有可见 KV 都参与 attention；top- k 是某些缓存方法额外施加的选择，或最终词表解码中的候选操作。

更关键的是，“苹果”“红色”和“杯子”对应不同解码时刻：

$$q_{\text{apple}} \rightarrow A(q_{\text{apple}}, K, V),$$

$$q_{\text{red}} \rightarrow A(q_{\text{red}}, K, V),$$

$$q_{\text{cup}} \rightarrow A(q_{\text{cup}}, K, V).$$

三个 query 来自不同前缀，具有不同 hidden state 与 softmax 分母。模型生成到“苹果”时自然读取对象证据，生成到“红色”时再读取颜色证据。FMBC 却把它们写成同一静态列

$$c_i = [c_i^{\text{apple}}, c_i^{\text{red}}, c_i^{\text{cup}}]^\top$$

并据此判断视觉 KV 是否线性可替代。

该线性相关性不代表真实解码中的可替代性。如果第一步把“苹果”改成“梨”，后续“红色”和“杯子”的 query 都会随前缀变化。因此一条 greedy trajectory 上的多个局部 margin 不是同时成立的固定坐标。

“红苹果”作为单一词表 token 也不能挽救方法：

- 若只有一个当前 margin, basis selection 退化成标量贡献排序；
- 区域内均匀 attention 可能正是聚合颜色与对象信息所需，不能只留一个线性代表；
- 若进一步合并相似视觉 token，则退化为普通 visual-token merging。

若修正为“取得每个 future query，再保留各时刻所需视觉 token 的并集，并在用后释放”，basis 部分会变得多余，整体退化为拥挤的 future-attention/lookahead cache scheduling。

6.4 第二层问题：signed veto 与 RRQR 不匹配

一个视觉 token 可能对“苹果相对梨”为正，却对“有杯子相对无杯子”为负，因此没有稳定的全局 positive/veto 划分。普通 RRQR 允许

$$c_i \approx \sum_{j \in B} \alpha_j c_j, \quad \alpha_j \in \mathbb{R},$$

而真实 attention 聚合使用非负、归一化且随 query 改变的权重。“在线性 span 中可重构”不等于“在 attention 中可替代”。若要保持实际语义，应改为逐自回归状态的 convex/conic covering；但这样一改，普通 RRQR 又不适用。

FMBC 因而存在两个互相强化的错误：

- (1) 自回归时序被压成静态 future-margin 空间；
- (2) 静态空间内部采用不符合 attention 非负归一化结构的线性重构。

6.5 机制级 related-work 查杀

FMBC 组件及最近工作	已有机制	重叠判断
RRQR/CSS: SPARE	将 visual-token pruning 写成 CSSP，使用 RRQR、Gram-Schmidt 与最大投影 residual 逐列选择	几乎直接重叠
条件化子空间: ResPrune	text-conditioned subspace reconstruction，每轮加入 residual energy 最大的视觉 token	直接重叠
输出敏感度: ZOO-Prune	通过扰动估计视觉 token 对输出的 sensitivity，并结合 diversity	信号和目标层面重叠
互补证据: SPARE , AnchorPrune	anti-relevance，或 relevance anchor 加 complementary context	与 veto/互补证据概念重叠
语义支持: SADT	用 logit lens 判断高 attention 区域的 value 是否支持输出词	语义诊断直接相邻
负视觉信号: One Token , Two Fates	把被裁视觉 token 构造成 latent negative sample	反证思想重叠
压缩后验证: VeriCache	用压缩 cache 草拟并由完整 cache 验证	验证闭环重叠

没有检索到一篇论文完整复制“future-margin matrix、signed veto、RRQR/CSS、重放补 residual”这一整套组合。但组合不等于独立核心创新：

conditioned matrix + RRQR/CSS + residual greedy

已经与 SPARE 和 ResPrune 高度一致。把输入从视觉 embedding 换成 future-margin attribution，更可能被视为目标矩阵替换；重放验证又与 VeriCache 相邻。

唯一表面未被完整覆盖的是“在 future-margin contribution matrix 上构造有符号锥，保留不能被支持列替代的 veto 列”。但该部分同时受到自回归静态化与 attention 非负归一化问题影响，尚不是定义稳定的新原理。

6.6 最终判断

FMBC 的问题不是少一个正则项，而是核心抽象不符合自回归解码：

不同时间、不同前缀下的未来 margin 不能被无条件视为固定线性证据空间；
修正这一点后，basis selection 的核心 novelty 随之消失。

综合查重后，严格 novelty 应从初始 7.5 下调到约 5-6。该方向最终为 **淘汰**，且不应再以“换矩阵、换分解方法”的形式重新包装。

第二部分 总结

7 反复出现的错误

7.1 成熟算法超级大聚合

Hall、Rado/matroid、zonotope、Farkas separation、EVT、permutation test、CSP、sheaf、network flow、SPRT、set cover、minimax/double oracle、delta debugging、causal mediation 和 CEGAR 都能生成清晰算法。但 reviewer 的共同判断是：若问题的核心经验现象没有自然要求这个算法，方法就会被视为“成熟算法迁移到 visual KV”，而不是视觉幻觉中的新原理。

7.2 切入似乎很对，实际非常狭隘

以下推理均不成立：

局部 attention output 保真 $\nRightarrow$ 最终回答正确，

支持图存在完整匹配 $\nRightarrow$ 图像中真的有对应实例，

future draft 上 cache 等价 $\nRightarrow$ 真实后续前缀上仍等价。

7.3 多步预测在自回归生成模式下的严谨性问题

很多候选将当前层的 attention、value-to-logit contribution 或固定 draft 轨迹当成未来的稳定对象。但自回归改变早期 token 后会改变所有后续 query。若未来状态真的已被完整跑出，方法又要解释为什么不直接使用这些 query，并证明额外 replay 可被摊销。

8 采用自动科研提示词，追加十轮

从开源自动科研系统抽取搜索与反驳结构。

IDEAgent。参考 <https://github.com/declare-lab/IDEAgent> 的 quality-diversity 搜索，把候选按

(failure mode, diagnosis, signal, intervention,

locus, objective, evaluation, relaxed assumption)

建立语义签名；分别维护 literature archive、accepted/rejected idea archive 与 ancestor chain。探索与改进分离，并禁止简单组合、换名和把已有模块搬到新任务。

Heuresis。 参考 <https://github.com/a-antoniades/Heuresis> 的 MAP-Elites cell-targeted ideation。某一语义 cell 拥挤时，不继续调参数，而要求改变 load-bearing mechanism；每个 idea 必须给出 executable contract、最小 falsifier、强基线和失败攻击。其局限也被保留：quality-diversity 能扩大覆盖，不保证扩大 novelty frontier。

AI Scientist v1/v2。 参考 <https://github.com/SakanaAI/AI-Scientist> 与 <https://github.com/SakanaAI/AI-Scientist-v2>。对每个候选依次搜索 exact phrase、机制同义词、相同任务、相同实验设计和不同术语下的近邻，并明确写出“最可能杀死 novelty 的工作”；检索结果必须回流到 idea revision。

CodeScientist。 参考 <https://github.com/allenai/codescientist> 的 paper-code 联合搜索。候选必须列出可证伪假设、对照组、主要指标、强基线、最小 pilot、依赖项、工作量与放弃条件。本任务没有运行 pilot，但用这些 executable-contract 约束排除了只能提供漂亮数学叙述的候选。

ResearchAgent 与 Agent Laboratory。 参考 <https://github.com/JinheonBaek/ResearchAgent> 的 Problem-Method-Experiment 分解，为 novelty、feasibility 与 utility 分别审查；低分轴不能由其他高分项平均补偿。Agent Laboratory 的启发是让具体否决理由回流到方法与实验定义。

最终合成提示。 追加十轮采用以下约束：

- (1) 先列语义签名和最接近的已拒绝祖先；
- (2) 写出唯一 load-bearing mechanism，不允许若干已有模块并列；
- (3) 指定最可能杀死 novelty 的 related work 并做机制级差分；
- (4) 给出核心经验现象、可证伪预测、强控制组与计算预算；
- (5) reviewer 主动执行 exact、mechanism、task、evaluation 与 synonym 五类检索；
- (6) 使用三审合取门槛，由最低分而非平均分决定通过；
- (7) 赛道拥挤时下一轮必须换因果对象或干预原语，不继续修饰上一方案。

该流程产生 causal intervention、sequential testing、signed multicover、minimax、behavioral predicate search 与 cross-modal handoff 等不同候选，但也支持 *AI Research Agents Narrow Scientific Exploration* (<https://arxiv.org/abs/2605.27905>) 的警告：自动科研系统容易把成熟算法迁移到新对象，并把“组合罕见”误认为“领域原理新颖”。

结果：

| Idea | 方法 | 分数 | 失败原因 | |—|—|—:|—| | 51 | VisPF | 4 | query-aware page retrieval 与决策证书已有强近邻 | | 52 | MKVC | 5 | K/V permutation 更像昂贵诊断，且 exchangeability 不成立 | | 53 | FMBC | 7.5 / 无效 / 7 | Grok 仅为 7；RRQR、residual

add-back、full-cache verification 分别与 SPARE、ResPrune、VeriCache 重叠 || 54 | CEGAR-VKV | 7.5 / 8 / 3 | Grok 判定只是把 CEGAR 模板迁移到 KV cache, 且需要反复 replay || 55 | PairGuard-KV | 6 | ‘2×2’ 成对干预成本高, 与 interaction attribution 接近 || 56 | LeaseSPRT-KV | 5 | 通用 SPRT 迁移, paired replay 昂贵, 自回归观测也不满足简单 i.i.d. || 57 | WitnessCover-KV | 4.5 | 本质是 signed future claims 上的 set-cover || 58 | MinimaxKV | 3.5 | 通用 minimax/double-oracle 迁移, 计算重且未必改善平均指标 || 59 | DeltaKV | 3 | 直接迁移 ‘ddmin’, 非单调且只对冻结轨迹成立 || 60 | RelayKV | 5 | causal mediation/视觉到文本的信息接管已有近邻, 并需多次干预 |

也就那样, 53 看着高。但还是被否决了, 因为它与 SPARE、conditioned subspace/residual greedy 与 ResPrune、full-cache verification 与 VeriCache 直接重叠, 因此淘汰。堆得多罢了... 效果还不知道呢

第三部分 完整 Idea 1–60 摘要

把这一段复制给 gpt 就能生成完整方法了，如果你想看某个点完整版的话。全在这里放不太现实。

Idea 1: Prospective Evidence Coalition KV Control. 每隔若干正式 token 生成短 future draft，对同一草稿分别做 full-visual-KV 与 null-visual-KV replay；从 null cache 分组恢复视觉区域，寻找能改变高风险未来承诺的最小 evidence coalition，再回滚草稿并门控正式分支 KV。评分为 8/8.5/8（旧协议）。用户手审指出它本质是“不提交的多步 greedy lookahead”，再叠加 full/null replay 与区域恢复，约 $19\times$ 推理成本；高分作废。

Idea 2: Rejection-Credit Speculative Grounding (RCSG). 稀疏视觉 drafter 与完整视觉 verifier 做 self-speculative decoding；首个 rejection (y^-, y^+) 被当作语言先验近邻反事实，并以

$$c_i = a_i \langle W_O V_i, u(y^+) - u(y^-) \rangle$$

形成视觉纠错 credit ledger，随后给原视觉 KV 加有界 attention bias。评分 7.4/9/6。Grok 将“视觉受限 drafter 加 dense verifier”视为已有 MLLM speculative decoding 近邻，rejection credit 不足以形成新范式。

Idea 3: Future Decision-Certificate Cache (FDCC). 用 block/tree speculative decoding 获得未来分支；把每个未来 grounded token 相对语言先验竞争项的 signed visual margin contribution 组成约束族，求同时保持整棵未来决策树 margin 的最小视觉 KV coreset。评分 7.4/9/5。本质仍接近 future-query/lookahead KV selection 加 margin-preserving coreset，树草稿与优化成本也偏重。

Idea 4: Hadamard-Coded Causal Masking (工作标签). 用 Hadamard/随机编码的成组视觉 mask，在少数 multiplexed 测量中恢复各视觉区域对 future logit margin 的因果贡献，以避免逐区域 forward。评分 5.8/未触发/未触发。编码 mask、group testing 与 compressed-sensing attribution 均有充分近邻，只是把通用归因迁移到视觉 KV。

Idea 5: Kinetic Evidence Frontier (工作标签). 不直接生成 future token，而由最近 query 的运动估计未来 query 可达区；把视觉 key 看作线性函数，保留可能进入未来 attention 上包络或改变 signed evidence boundary 的 KV。评分 5.8/未触发/未触发。与 Foresight、future-query cache prediction 和几何 MIPS/upper-envelope 接近；query 轨迹假设与 softmax 误差界不稳。

Idea 6: SEW-KV (工作标签)。 对视觉块做自适应 Monte-Carlo/importance sampling, 以序贯置信区间判断稀疏 cache 是否已足够近似完整 attention 或 future margin; 证书未收敛时继续恢复块。评分 5.8/未触发/未触发。与自适应稀疏 attention、PAC/Monte-Carlo attention approximation 高度重合, 幻觉部分主要是应用替换。

Idea 7: Hall-Certified Prospective Matching Cache (HPMC)。 将 future claims 与视觉区域构成带容量二部图; 若某 claim 子集 C' 满足 $|N(C')| < |C'|$, 则 Hall deficit 指出多个声明重复借用同一视觉证据。保留最大匹配、最小 deficit cut 与 alternating-path exchange set 中的 KV, 并沿增广路径恢复冷区域。评分 8.2/9/7, 因第三审等于 7 而失败。用户进一步指出它无法直接检测“六根手指说成五根”, 且是现有 counting/局部干预的下位替代。

Idea 8: Future Signed Heavy-Hitter Cache (工作标签)。 对多个 future query 的 $QK \times$ signed value-to-logit contribution 做 CountSketch/重频项恢复, 寻找未来持续支持或否决 claim 的视觉 KV, 而不扫描全部 token。评分 6.6/未触发/未触发。CountSketch/MIPS heavy hitters 与 future-query KV recall 近邻很强, signed contribution 只是 scoring signal 变化。

Idea 9: Extreme-Witness Future Cache (EWFC)。 将“在大量 patch 中取最大证据”视为多重比较偏差; 对 future claim 的 signed grounding score 做空间去簇、POT/GPD 极值尾拟合和 extremal-index 校准, 再以 e-BH/alpha-investing 控制 future-window FDR。只保留显著正/负极值簇与尾估计边界样本。评分 8/8/6。最终被视为把通用 EVT/e-value 校准迁移到视觉 patch evidence, KV 动作仍是阈值保留/恢复。

Idea 10: Permutation-Certified Binding Cache (PCBC)。 固定 future query 的 attention 权重多重集与 value semantic score 多重集, 通过空间块 permutation 检验真实 K-V 配对是否比随机重配更支持 claim; 以

$$(\alpha_i - \bar{\alpha})(x_i - \bar{x})$$

的 pivotality 保留正见证、负反证与检验边界 token。评分 7.2/9/7。第三审等于 7; 更像 causal attribution/permutation test 的新检验, 不是新 KV 管理原理。

Idea 11: Zonotope-Separated Future Cache (ZSFC)。 将每个视觉区域对 h 个 future claim 的 signed correction 写成列 $c_i \in \mathbb{R}^h$, 所有可逆 gate 的可达修正组成 zonotope; 若目标 margin 向量在误差盒扩张后的 zonotope 外, Farkas separating hyperplane 给出联合不可救证书, 再以 column generation 恢复 reduced-cost 最大的 KV。评分 7.8/9/7。线性化与 softmax renormalization 无法覆盖真实 decoder 非线性, 整体也像 LP/column-generation 移植。

Idea 12: HALO: Hallucination-Aware Logic Oracle. 将未来对象、属性、关系声明与视觉候选写成 CSP/factor graph, 通过 arc consistency、all-different constraint 与 minimal unsat core 定位联合不可满足声明, 再据候选域恢复视觉 KV。评分 4.8/未触发/未触发。scene-graph grounding、CSVG/CSP 与 unsat-core reasoning 都有直接近邻, KV 管理只是符号诊断后的附加动作。

Idea 13: Sheaf-Laplacian Obstruction Cache (工作标签)。 把跨 claim、区域和层的局部证据视为 cellular-sheaf sections, 以 sheaf Laplacian 能量或 cohomology obstruction 定位不能拼成 global section 的未来声明, 并按有效电阻或谱 leverage 保留视觉 KV。评分 5.2/未触发/未触发。Transformer 张量未证明满足所借 sheaf 结构; 去掉拓扑术语后仍是图一致性检测加谱 token pruning。

Idea 14: Proof-Carrying Evidence Flow Cache (工作标签)。 将视觉证据到多个 future claims 的传播写成多商品流; min-cut 或 flow infeasibility 充当 hallucination certificate, cache 保留 terminal cut sparsifier、瓶颈边与恢复可行性所需 KV。评分 4.7/未触发/未触发。attention-flow attribution 与 graph cut 已有工作, 将 attention 当守恒流并把流可行性等同 semantic grounding 缺乏基础。

Idea 15: Query-Addressable Counter-Witness Cache. 为未来高风险 claim 构造 synthetic KV dipoles: key 分别沿 $\pm \hat{q}_j$ 偏移, value 分别写入 claim 的负/正语义方向; 校准后只对目标 query 下调幻觉 margin, 对近正交 query 一阶抵消。评分 6.2/未触发/未触发。synthetic KV、activation steering 与 absence evidence 均有近邻; 任意 KV 注入的 off-target 稳定性不足。

Idea 16: Future Visual Controllability. 用短 draft 构造文本 echo 的严格下三角矩阵 F 、有限时域增益 $G = (I - F)^{-1}$ 与视觉控制矩阵 B ; 在保持当前 next-token attention output 不变的 null space 中, 求最小范数视觉 V 编辑以压制未来文本自激励模式。评分 4.3/未触发/未触发。与 cache/activation steering、closed-form editing 接近; 局部末层线性化与未来可控性均不稳。

Idea 17: Visual Evidence Ledger. 联合分配多个 future claims 到视觉 token, 并惩罚语义无关 claims 重复消费同一证据; 优化后用最小范数 key edit 实现目标路由, 同时保持每个 future query 的视觉 partition mass。评分 5.7/未触发/未触发。本质接近 OT/coverage/diversity-aware attention routing; “同一 token 不应被多个 claim 共享” 对对象、属性、关系并不普遍成立。

Idea 18: TubeCert-KV: Robust Query-Tube Certificate. 由历史 draft 误差构造未来 query 椭球，对每个视觉 key 求闭式上下界，并把 signed value evidence 合成为整个 query tube 上的 margin interval；按最坏情况恢复 support/veto token。评分 4.1/未触发/未触发。robust attention、ellipsoidal bound 与 certified token pruning 已覆盖主干；证书仅保护局部 direct-contribution surrogate，且界可能过松。

Idea 19: Text-Visual Twin / Evidence-Lineage Cache (工作标签)。 沿 draft 中 attention/value direct-logit contribution 追踪视觉证据如何经 text relay token 传播；future claim 若只剩文本副本而原始视觉 lineage 坍塌，则 pin 或恢复源视觉 KV。评分 5.7/未触发/未触发。attention rollout、ALTI-Logit、circuit tracing 与视觉 relay 已覆盖大部机制，lineage 驱动 cache 是组合扩展。

Idea 20: Future Visual Experiment Cache (F-VEX)。 把 future semantic alternatives 当作多假设检验，把视觉 KV 当传感器；选择使最弱候选对 Chernoff information 最大的 KV 集，以保留最能区分 claim 与竞争项的视觉反证。评分 4.3/未触发/未触发。属于经典 sensor selection/active hypothesis testing 迁移；Chernoff 可加性及从 attention/value 得到可靠 likelihood 的假设不成立。

Idea 21: Counterfactual Attention Shield (工作标签)。 用删除单个/分组 KV 后 softmax numerator 与 denominator 的闭式更新，估计每个 future claim 的精确局部删除效应；保护删除后会放大可疑 claim 的 counter-evidence/sink，淘汰安全项。评分 4.2/未触发/未触发。attention token ablation、closed-form deletion、semantic sink 与 output attribution 已有近邻，仍是更精确 importance score。

Idea 22: VetoKV。 为 future claim 与语义替代项计算 signed visual value-to-logit contribution，专门保留或恢复反对高语言先验 claim 的低-attention veto KV，而不只保留正证据。评分 6.7/未触发/未触发，是未进入复审者中的最高分。但 SADT、negative visual evidence、contrastive hallucination mitigation 与 output-aware KV 已覆盖主要动机。

Idea 23: Visual Round-Trip Cache。 构造 claim $\rightarrow$ region $\rightarrow$ claim 的冻结转移：key 负责寻址，value 经 unembedding 解码回候选词；保留形成正确自返回或导向关键替代词的 patch，删除“key 看似相关但 value 语义不闭环”的视觉项。评分 5.6/未触发/未触发。与 SADT 的 value semantic checking、VGA 与 OBCache 的 K/V 联合重要性重叠，round-trip 是评分重写。

Idea 24: Future Claim-Sufficient Two-Tier KV。 对 future query span B_Q 与 claim-contrast span B_U 保存每个区域的低维 guard statistics

$$\hat{k}_i = B_Q^\top k_i, \quad \hat{v}_i = B_U^\top v_i,$$

再由 guard tier 按需将 dormant full KV 提升到 active tier。评分 3.4/未触发/未触发。与低秩 KV、query-specific projection、ResKV/ThinK 重合；“充分”只对固定 lookahead subspace 成立。

Idea 25: Rado-Certified Matching Cache (工作标签)。 把 Hall 的“不同 claim 需要不同区域”推广为 Rado/matroid independent representatives: 不同 future claims 不仅匹配不同区域, 所选证据还必须在语义贡献空间中线性或拟阵独立; 保留 basis 与 exchange candidates。评分 4.1/未触发/未触发。数学定理迁移明显, claim、区域与向量独立性的语义对应缺乏依据。

Idea 26: Exact Spatial Jackknife KV。 一次累计每个空间块的 softmax 分母质量 Z_{jB} 与 value 分子 N_{jB} , 用

$$o_{j,-B} = \frac{N_j - N_{jB}}{Z_j - Z_{jB}}$$

精确得到删除块后的 attention output, 无需区域 forward; 沿 future claim margin 方向得到 signed leverage 并决定 pin/prune。评分 3.3/未触发/未触发。与 CAOTE/closed-form attention ablation 接近, 创新主要是把 current token 换成 future claim 与空间组。

Idea 27: Claim-Deadline Visual KV。 将 future contribution sequence 编译为每个视觉区域的一个或多个需要区间, 运行时执行 `activate(i,s-Δ)` 与 `deactivate(i,e)`; 原始 KV 留在 dormant pool, 轨迹偏离时重编译后续生命周期。评分 4.4/未触发/未触发。与 cache prefetch、TTL/lifetime scheduling、LAQ/Expected Attention 的未来重要性预测同构。

Idea 28: BalanceKV (reviewer 工作标签)。 将视觉 token 对 future margins 的正、负向贡献视作 signed vectors, 以 discrepancy/vector-balancing 选择小 coresets, 分别保存 support mass 与 veto mass, 并用 dual witness 判断预算不足。评分 2.2/未触发/未触发。属于标准 discrepancy/coresets 迁移; softmax 非线性与 token 依赖破坏向量可加性。

Idea 29: Antisymmetric Relation-Edge Cache (ARE-KV; 也出现 FCSGG 标签)。
在视觉图有向边 $i \rightarrow j$ 上构造

$$K_e = (K_j - K_i)/\sqrt{2}, \quad V_e = (V_j - V_i)/\sqrt{2},$$

用 future relation flow 判断方向一致性，并在风险 span 懒加载 edge read，使关系本身成为可寻址 KV。评分 4.1/未触发/未触发。EdgeConv、scene-graph relation feature 与 relation-sensitive head 已有近邻，差分边 cache 是昂贵的工程表示扩展。

Idea 30: GQA Physical-Pool / Per-Q-Head Logical-View Split。 每个 KV head 只保留一份物理视觉池，但为共享它的每个 query head 建立独立 sparse index view；future draft 决定各 Q-head 可见的视觉地址，避免对象、属性、关系 head 争用统一剪枝集合。评分 4.5/未触发/未触发。与 Quest、MagicPIG、per-query sparse attention 和 GQA-aware KV indexing 接近，更像高效 attention 系统设计而非新 hallucination 原理。

Idea 31: Dual-Channel Witness Run Break。 对短 future draft 中的每个视觉 token，分别用固定随机超平面计算 query-key 地址一致位和 residual-value 语义一致位；两类比特同时成立才记一次命中。以跨 future step 的最长连续命中游程作为视觉见证，并用 Bernoulli run 的有限状态递推设置阈值。初审 3.4。SimHash/LSH、future-query cache selection 与游程检验均有成熟来源；独立、正交且同分布零假设也不符合真实 attention。

Idea 32: 视觉 attention 剂量-反应边界 (正式名称未恢复)。 沿视觉 attention logit 缩放系数构造连续干预路径，观察 future draft 候选词 margin 随强度的曲线；以过零点、临界剂量或灵敏度管理视觉 KV。初审 4.1。attention boosting 与温度缩放已拥挤，softmax 下 margin 对缩放不保证单调，根不存在或多根时定义不稳。

Idea 33: 提交式 draft 槽位视觉 KV 嫁接。 在已提交短 draft 中寻找视觉接收弱、却会被后续 token 高频访问的功能词或标点槽；将真实视觉 token 的完整 KV 经精确 RoPE 迁移后复制到该槽某个 GQA group，使其成为靠近解码尾部的视觉 relay。初审 4.6。KV 搬移、cache splice、视觉记忆再注入与 anchor token 已有近邻；覆盖功能词 KV 还可能破坏语言语义。

Idea 34: RoPE 相位锁失效事件。 将 RoPE 维对写成复数并移除已知相对位置旋转，测量 future queries 与视觉块之间的内容相位合成长度；若 active blocks 均不能形成稳定 phase lock，则恢复越阈冷块。初审 2.8。RoPE 相位分析、位置重绑定与 future-query retrieval 已存在，“真实视觉证据必形成跨 token 锁相”也没有机制依据。

Idea 35: 视觉证据负债越界事件。 比较每个 future step 中视觉 attention write 与文本 attention write 对 residual innovation 的对齐，累积为 e-process；最大值越过 Ville 阈值时，解释为 draft 持续转向语言先验，并恢复最能解除越界的视觉块。初审 3.5。接近 M3ID/PAS 类视觉依赖衰减指标，只是增加 anytime-valid 统计；条件均值假设无法从冻结 VLM 保证。

Idea 36: 视觉码长倒置事件。 把 future residual innovation 随机投影到低维, 分别由视觉 write 与文本 write 构造逐步 Student- t 预测码; 若视觉码长显著更大, 则认为语言通道更能解释未来, 并恢复最能缩短视觉码长的 KV。初审 4.1。prequential/MDL、视觉-文本依赖比较与 future draft 都是已有工具, 拟合码长也不是真实生成似然。

Idea 37: 视觉响应球形化事件。 收集 future steps 与 attention heads 的单位视觉 write, 计算二阶矩阵与球面对称矩阵 I/r 的距离; 响应近似各向同性时恢复能产生方向性 spike 的冷块。初审 2.6。DSCR 已把视觉 key 各向同性与幻觉联系起来, 从 query-conditioned write 球形化到内容幻觉仍缺可靠因果链。

Idea 38: 中心-周边差分视觉 KV (正式名称未恢复)。 以视觉 patch 为中心、空间邻域为 surround, 构造类似 lateral inhibition/unsharp masking 的正负 attention/write 对; 只有 future claim 的中心支持超过邻域干扰才保留。初审 2.5。Differential Transformer、attention-space contrastive guidance、局部-全局解码与 DSCR/KVSmooth 都有近邻; 固定邻域也不等于对象边界。

Idea 39: 多图像证据银行与 Viterbi 路径 (正式名称未恢复)。 将不同图像/视图的视觉 KV 分组, 先做 image-level grouped softmax, 再在 future claim 序列上用带切换代价的 Viterbi path 选择持续一致的证据银行, 防止实体描述跨图片漂移。初审 3.0。grouped/hierarchical attention、多图路由与 structured attention 已有大量工作, 且与单图 CHAIR/AMBER 主场景不对齐。

Idea 40: Future-Driven Visual-KV Bitplane Tiering。 视觉 KV page 由低比特 base 和可挂接 residual bitplanes 组成。future draft 持续使用的 page 恢复高位残差, 未使用 page 卸下残差, 在固定显存预算下切换 INT2、INT8 或近 BF16。初审 4.8。mixed-precision KV、progressive residual quantization、CONF-KV、QuantSpec 与 VeriCache 近邻很强, 也缺少“视觉 KV 量化是幻觉主因”的现象。

Idea 41: 地址-语义-空间三阶绑定检验 (正式名称未恢复)。 通过受约束的视觉 K/V/位置置换, 试图在保留两两边际的同时破坏 query-key 地址、value 语义与空间位置的三阶绑定; future claim 仅在原三元绑定下成立时保留对应 KV。初审 3.0。SADT 已检查 attention/value 语义一致性, K/V shuffle 也是常见消融; 同时保持所有两两边际的置换通常不可执行。

Idea 42: Time-Unrolled Hall Matching。 把 future draft 中同一实体的多次提及展开为时间节点, 以外观、空间与语义一致性边连接区域, 在 time-unrolled graph 上做 matching/min-cost flow; 后续属性通过 identity switch 借另一对象证据时产生 deficiency。

初审 3.2。它是 Hall matching 的扩展，与多目标跟踪、视觉共指和全局 phrase grounding 重叠，且未修复 Hall 边不可靠与作用域窄的问题。

Idea 43: Post-Selection Calibrated Extreme Visual Witness (正式名称未恢复)。

不直接相信 attention 最大 patch，而把最大值当作 post-selection statistic；用 EVT、Gaussian random-field peak 或 spatial scan statistic 校准局部峰/盆地显著性。初审 3.0。校正 winner's curse 只能证明峰值异常，不能证明 patch 语义支持 claim，仍是校准后的 attention top- k 。

Idea 44: Visual Innovation Cache。 估计文本 KV 或语言先验张成的子空间，将视觉 value/write 投影到其正交补，只保存不能由文本子空间解释的 innovation residual；future draft 需要某创新方向时恢复对应 KV。初审 3.0。ACG、HulluEdit、ResPrune 与 SPARE 已使用视觉-文本正交分解或条件子空间重构；正交于文本不等于视觉真实。

Idea 45: Coded Visual-Provenance Receipt。 向视觉 KV 或 attention write 注入相互正交的 Hadamard/随机小扰动，再从 future hidden states 用 matched filter 解码“回执”，用少量 forward 判断哪些视觉 token 确实传播到 future claim。初审 3.2。activation patching、coded perturbation、zeroth-order attribution 与 HalluTrace 已覆盖主要组成；标签注入会改变被测网络，多层非线性后也无法干净解码因果来源。

Idea 46: Future Head-Coalition Cache。 在未若干层对视觉 attention heads 做单头和成对开关的 2×2 factorial intervention，以 difference-in-differences 测量 head synergy 对 future claim margin 的作用，再把视觉 KV 预算分配给反幻觉 coalition。初审 4.4。head ablation、path patching、Shapley interaction 与 hallucination heads 已成熟；成对实验随 head 数增长过快。

Idea 47: K-Indexed V Materialization。 保留低比特/摘要 key 作为常驻索引，把昂贵 value 放冷端；future query 先扫描 key，只为可能提供 support/veto 的位置 materialize values。初审 2.0。ShadowKV、RetrievalAttention、InfiniGen 与 SpeCache 已广泛研究 key 常驻、value offload 和 query-aware prefetch；加入幻觉语义只是任务迁移。

Idea 48: Non-Monotone Layerwise Visual-KV Re-entry。 早层剪掉的 layer-local 原始视觉 KV 存在冷池，future query 可让某 patch 在中层缺席、深层重新进入；恢复冷页时同步解除无用热页以保持预算。初审 1.8。PLPHP、IdleViT、HAE、HybridKV 与 token recovery/re-entry 已覆盖近乎相同的层间非单调性。

Idea 49: Predictive-Equivalence/Bisimulation KV Merging. 把视觉 KV 看作对 future queries 产生 attention/output 行为的状态；若两个 token 在当前 draft query set 上不可区分，则合并为同一等价类；出现可区分 future trace 时按 CEGAR/partition refinement 拆分。初审 2.8。query-aware KV merging、Attention Matching、KVSculpt 与 predictive-state abstraction 已提供骨架；有限 draft 等价不能保证后续 prefix 下等价。

Idea 50: Integral Evidence Polytope / Projective-Softmax Certificate. 把每个视觉 token 对 future claim margin 的 softmax numerator/denominator contribution 做齐次提升，在固定预算下用 LP/MILP 选子集；以 Farkas 型不可行证书说明某 claim margin 不能保持。初审 2.5。attention coreset、Expected Attention、CAOTE 与 certified KV compression 已覆盖目标；softmax、多层反馈和整数选择使所谓精确线性证书不成立，MILP 成本也过高。

Idea 51: VisPF. 将视觉 KV 分成 GPU active pages 与 cold pages。对每个 future query，以页内 key 的中心与半径计算该页可达到的 attention 上界，并进一步界定遗漏 value 对候选词 logit margin 的最坏漂移。若冷页联合上界足以翻转 argmax，则像 page fault 一样逐页恢复；否则给出本步 argmax-preservation certificate。初审 4，外审未触发。该方向同时接近 Quest/InfiniGen 的 query-aware page retrieval、SpecKV/LAQ 的 future query，以及 AXIOM-KV/VeriCache 的误差或决策证书；多层 VLM 中单层 attention bound 也难紧致传播到词表 margin。

Idea 52: Matched-Knockoff Visual Cache (MKVC). 为每个视觉 token 寻找空间、key norm 与局部统计相似的 donor；保持原 keys 不变，但在 matched group 内交换/置换 values，构造 attention address 近似不变、K-V 语义绑定被破坏的 knockoff cache。比较原 cache 与 knockoff cache 的 future claim/counterclaim margin，以定位“不是只因被访问，而是 value 确实支持”的视觉 KV。初审 5。SADT、value-zeroing/masking 与 K/V permutation 已覆盖诊断动机；视觉 token 的 exchangeability 也不成立，方法首先是昂贵诊断而非自然缓存策略。

Idea 53: Future Margin Basis Cache (FMBC). 生成短 future draft，在各未来位置保留当前 token 与最强替代词，为每个视觉 token 构造其对全部 future margins 的 signed contribution vector；用 RRQR/CSS 选择线性独立 evidence columns，保护不能由正向列重构的 veto columns，再以 reduced-cache replay 和 residual add-back 闭环。评分 7.5/Gemini 无有效 JSON/7。用户手审判定其把不同 prefix/query 静态化为一个固定列空间；RRQR/CSS 与 SPARE、conditioned subspace/residual greedy 与 ResPrune、full-cache verification 与 VeriCache 直接重叠，因此淘汰。

Idea 54: CEGAR-VKV。 从激进压缩的视觉 cache 开始, 在 full cache 与 reduced cache 上比较短 future trace; 若 reduced cache 新增 claim、降低视觉依赖或翻转关键 margin, 则把首次差异当 counterexample。通过 pooled block ablation 定位能解释 counterexample 的缺失视觉块, 加入 cache 后重验, 直到行为谓词满足或达到预算。评分 7.5/8/3。Grok 指出它本质是把 CEGAR 的 counterexample-refine-verify 模板迁移到 KV cache, 并与 full-cache verification、token reclamation 与 adaptive retrieval 接近; 多轮 replay 也削弱成本优势。

Idea 55: PairGuard-KV。 从 future draft 提取 subject-relation-object 或 object-attribute claim 及 counterclaim。先由空间邻接与特征提出少量视觉块对 (i, j) , 再执行 both、 i -only、 j -only、neither 的 2×2 cache intervention, 用 difference-in-differences 得到超出单块作用的 signed pair synergy。高协同块对获得不可拆分 pair lease, 关系短语结束后释放。初审 6。与 MultiSHAP、interaction attribution 与 relation-aware token selection 相邻; 候选对和干预次数仍高, pair synergy 也随 prefix 与 attention normalization 改变。

Idea 56: LeaseSPRT-KV。 每个 future claim 创建视觉 block leases。正式解码每隔若干 token 轮换测试一个块, 在 full 与 block-drop 的末层 replay 上取得 claim margin 差并更新 log-likelihood ratio/e-value。越过必要阈值则续租/固定, 越过冗余阈值则驱逐, 未决块继续保留; 共享块只有所有 claim leases 都关闭才可删除。初审 5。SPRT 是通用成熟算法, CONF-KV、RetentiveKV 与 KVSmooth 已有置信/保留期机制; paired replay 成本明显, 自回归观测也不符合简单 i.i.d. likelihood。

Idea 57: WitnessCover-KV。 把 future claims、counterclaims 与视觉块组成 signed incidence matrix, 用少量 pooled-drop probes 估计每块对 claim 的 support/refutation。cache selection 写成 k -witness multicover: 每个正 claim 至少保留两个空间分离 supporter, 每个 counterclaim 至少保留一个 refuter, 再用 greedy submodular cover 删除 coverage-dominated blocks。初审 4.5。SCoRe、CoIn 等已经用 coverage/informativeness 做视觉 token reduction; 把 universe 换成 signed future claims 仍是 set-cover 迁移, pooled probe 也受非加性 attention 影响。

Idea 58: MinimaxKV。 将固定预算 cache 写成

$$\min_{C: |C| \leq B} \max_{c \in C_{\text{future}}} R(c, C).$$

攻击者选择当前 cache 下风险最大的 future claim/counterclaim, 防守者通过 pooled ablation 找到降低该风险的视觉块交换; 以 double-oracle 迭代两三轮, 针对尾部/稀有幻觉而非平均 attention。初审 3.5。minimax/double-oracle 是明显通用算法迁移, 与 worst-case token selection、VASparse 接近; 每轮还需风险搜索与干预, 也缺少改善 CHAIR/AMBER 平均指标的理由。

Idea 59: DeltaKV。 以 full-cache future claim vector 定义行为安全谓词，例如“不新增 claim、不削弱 grounded claim 的视觉依赖、风险 claim margin 只能下降”。随后对视觉块运行 delta debugging：尝试删除一半，谓词成立则接受，否则拆分并测 complement，最后用 singleton check 得到相对该轨迹的 1-minimal cache。初审 3。ddmin 是直接成熟算法迁移；softmax 归一化使删除效应非单调，1-minimal 只对一条 frozen trajectory 成立，多轮 replay 也不轻。

Idea 60: RelayKV。 不以 attention 下降直接认定视觉 KV 无用，而检验视觉信息是否已被实际生成的文本 KV 因果接管。对 future claim 比较四种干预：保留/删除原视觉块，以及保留/屏蔽候选 text mediator；只有删除视觉块本身不改变 claim、但同时屏蔽 mediator 会恢复该影响时，才认定视觉 evidence 已 handoff，并允许删除原 KV。初审 5。LaT/MEMENTO、跨模态信息流、Intervene-All-Paths、KVERaser 与 causal mediation 已覆盖“信息转移到后续 token”；多干预 replay 成本不低，mediator 复现一个 margin 也不代表对其他 prefix 安全冗余。